

Smart-Planif : Système Intelligent de Planification Automatique et Adaptative

Projet de Master 2 Recherche

Spécialité : Optimisation des Ressources (Flotte & Personnel)

Partenaire : Ministère du Transport (Tunisie)

Année Universitaire 2025-2026

1 Introduction et Positionnement

1.1 Présentation du projet

Le projet *Smart-Planif* vise la conception et le développement d'un système intelligent de planification automatique et adaptative des ressources (flotte de bus et personnel) au sein du réseau de transport public tunisien. L'objectif est de générer des plannings journaliers et hebdomadaires optimaux, tout en permettant un réajustement en temps réel face aux aléas opérationnels (pannes, retards, incidents, absences). Ce système doit minimiser l'utilisation des ressources tout en maximisant la régularité et la ponctualité du service, répondant ainsi aux exigences de qualité de service (QoS) du Ministère du Transport.

1.2 Problématiques scientifiques centrales

Le projet s'articule autour de plusieurs défis scientifiques majeurs :

- **Optimisation combinatoire dynamique et stochastique (NP-difficile)** : Affectation véhicules/personnel sous contraintes multiples (capacité, fenêtres temporelles, maintenance, repos réglementaires, consommation).
- **Gestion de l'incertitude et réactivité en temps réel** : Problèmes de *dynamic rescheduling* nécessitant des décisions séquentielles sous incertitude [2].
- **Scalabilité et robustesse** : Traitement d'instances réalistes (grande flotte, milliers de trajets) avec des temps de réponse compatibles avec l'exploitation opérationnelle.
- **Intégration décisionnelle** : Articulation avec un tableau de bord unifié de suivi QoS pour le pilotage stratégique et opérationnel.

1.3 Concepts et approches mobilisés

La méthodologie repose sur un couplage interdisciplinaire entre Recherche Opérationnelle (RO) et Intelligence Artificielle (IA) :

- **RO** : Modélisation MILP et programmation par contraintes (CP-SAT) pour les planifications statiques [7].
- **Métaheuristiques** : ALNS et VNS pour la scalabilité sur des instances de taille réelle [4].
- **Apprentissage par Renforcement (RL)** : Agents PPO/DQN pour l'apprentissage de politiques d'adaptation en temps réel [6].
- **Apprentissage Automatique (ML)** : Prédiction supervisée des perturbations (retards, pannes) dans une logique *predict-then-optimize* [5].

1.4 Positionnement dans l'état de l'art

Smart-Planif s'inscrit dans la famille des *Dynamic Vehicle Routing Problems with Time Windows* (DVRPTW) et des *Crew Scheduling Problems* avec adaptation dynamique. Les travaux fondateurs [1, 3] ont démontré les limites des méthodes exactes pour des instances opérationnelles. L'état de l'art récent privilégie les architectures hybrides combinant métaheuristiques rapides et RL pour le *rescheduling* séquentiel, ou l'apprentissage supervisé pour la prédiction proactive des

perturbations [6]. Peu de travaux traitent spécifiquement du contexte tunisien (flotte hétérogène, données limitées, contraintes réglementaires locales), ce qui confère au projet une contribution scientifique originale et contextualisée.

2 Partie I – Recherche (Théorique et Méthodologique)

2.1 Revue de littérature structurée

La littérature mobilisée couvre trois axes complémentaires :

- **Scheduling dans le transport public** : VRP, VRPTW, Multi-Depot VRP, Crew Rostering et problèmes intégrés véhicule-chauffeur [3].
- **Algorithmes exacts vs approchés** : MILP, Column Generation, Branch-and-Price. Les limites de scalabilité des solveurs exacts sur des instances dynamiques sont bien documentées [7].
- **Métaheuristiques et IA modernes** : ALNS [4], VNS, algorithmes génétiques, ainsi que les cadres RL (MDP/POMDP) pour la prise de décision séquentielle et le *deep learning* pour la prédiction de trafic [5, 6].

2.2 Modélisation mathématique

Le problème est formulé comme un programme d’optimisation stochastique à deux étapes.

Ensembles et paramètres

- B : ensemble des bus, D : chauffeurs, T : trajets, $\mathcal{T}$: périodes discrètes, E : événements aléas.
- c_b : capacité du bus b , d_t : durée du trajet t , $[a_t, b_t]$: fenêtres temporelles.
- Coûts : carburant, pénalité de retard, heures supplémentaires, probabilités d’aléas $P(e)$.

Variables de décision

- $x_{b,t,d} \in \{0, 1\}$: bus b et chauffeur d affectés au trajet t .
- $s_{b,t} \in \mathbb{R}^+$: heure de début réelle du trajet.
- $y_{b,t,e} \in \{0, 1\}$: variable de réaffectation en cas d’aléa e .

Fonction objectif

$$\min \sum_{t \in T} (\text{coût}_{\text{carburant}} + \alpha \cdot \text{retard}_t + \beta \cdot \text{overtime}_d) + \gamma \cdot \mathbb{E}[\text{coût}_{\text{réajustement}}] \quad (1)$$

Contraintes principales

- Couverture exhaustive des trajets.
- Respect des fenêtres temporelles et des capacités.
- Maintenance préventive, repos réglementaires, compatibilité bus/chauffeur.

- Conservation de flux et continuité temporelle des plannings.
- Contraintes de robustesse (temps tampons, contraintes stochastiques).

2.3 Approches proposées

Trois niveaux de résolution sont envisagés :

Approche 1 : Baseline MILP : Modèle statique résolu via OR-Tools (CP-SAT) ou PuLP. Sert de référence comparative [8].

Approche 2 : Métaheuristique ALNS : Recherche à voisinage large adaptative personnalisée pour traiter des instances réalistes avec une scalabilité maîtrisée [4].

Approche 3 : Cadre hybride RL+ALNS (Innovant) : Un agent RL détermine le déclenchement et la stratégie de réoptimisation locale en temps réel, couplé à l'ALNS pour la recherche de solutions voisines [6].

Hypothèses et limites : Données partielles simulées ou issues du partenaire ; aléas modélisés par distributions (Poisson pour pannes, Gaussien pour retards). En l'absence de données massives immédiates, une simulation Monte-Carlo sera utilisée, avec un focus initial sur une ligne ou un dépôt pour la preuve de concept.

3 Partie II – Développement (Implémentation et Prototype)

3.1 Architecture technique

Le système repose sur une architecture modulaire et évolutive :

Couche	Technologies
Backend	Python 3 + FastAPI (API REST)
Optimisation	Google OR-Tools (CP-SAT + VRPTW) + ALNS personnalisé + Stable-Baselines3 / Ray RLlib
Base de données	PostgreSQL (flotte, personnel, trajets, historiques, logs d'aléas)
Frontend	Streamlit (prototype) ou React + Plotly/Dash (version finale)
Déploiement	Docker + serveur local ou cloud gratuit (Render / Hugging Face Spaces)
Simulation	Script Python : 50–100 bus, 200–300 trajets/jour, aléas Monte-Carlo

3.2 Implémentation des algorithmes

- **Module 1 : Générateur de planning statique** : Résolution du problème VRPTW via OR-Tools CP-SAT.
- **Module 2 : Détecteur d'aléas + réoptimiseur ALNS** : Réaffectation locale en < 60 secondes via destruction/construction itérative.
- **Module 3 : Agent RL** :
 - *État* : statut flotte + aléas courants.

- *Actions* : réaffectations bus/chauffeur.
- *Récompense* : $-\text{coût total} - \text{pénalité retard}$.
- **Intégration** : Endpoints API `/generate_plan` et `/replan` (temps réel simulé).

3.3 Prototype fonctionnel et Dashboard

Interface utilisateur

- Chargement des données (flotte, trajets).
- Génération de plannings journaliers/hebdomadaires.
- Simulation d'aléas (bouton *Incident*) $\rightarrow$ réajustement automatique.

Dashboard (exigences QoS)

- KPIs régularité/ponctualité : taux de retards, écart moyen, % trajets à l'heure.
- Taux d'utilisation bus/personnel, coût estimé, alertes maintenance.
- Graphiques interactifs (Plotly) + prévisions pour périodes spéciales.
- Export PDF/Excel des plannings.

Livrables Développement Application web unique, code source documenté sur GitHub, rapport technique complet.

4 Partie IV – Évaluation et Résultats Attendus

4.1 Métriques de performance

Métrique	Cible
Temps de planification statique	< 5 minutes
Temps de réajustement temps réel	< 60 secondes
Taux de ponctualité	$> 95\%$
Réduction des retards (scénarios 10–20 % d'aléas)	Significative (Monte-Carlo, 100 scénarios)
Taux d'utilisation des ressources	$< 85\%$ (prévention fatigue)

4.2 Scénarios de test

- **Cas simulés** : Données synthétiques réalistes (distributions Poisson/Gaussienne).
- **Cas réels** : Données terrain fournies par le Ministère du Transport (sous réserve de disponibilité).
- **Scénarios extrêmes** : Pannes multiples, pics de trafic, perturbations météorologiques.

4.3 Résultats attendus

- **Pour l'utilisateur** : Réduction significative des retards et amélioration mesurable de la ponctualité.

- **Pour l’administrateur** : Outil d’aide à la décision opérationnelle, intuitif et intégré aux processus métier.
- **Contribution au Dashboard Général Unifié** : Fourniture de KPI exploitables couvrant les trois axes QoS (Propreté, Sécurité, Régularité/Ponctualité).

4.4 Conclusion

Ce projet présente un équilibre structuré entre recherche théorique (50 %) et développement applicatif (50 %), strictement aligné sur les objectifs du Ministère du Transport. En combinant optimisation combinatoire, métaheuristiques avancées et apprentissage par renforcement, *Smart-Planif* propose une réponse innovante et contextualisée aux défis de la planification dynamique dans les réseaux de transport émergents. L’intégration native des exigences QoS dès la phase de conception garantit une transférabilité opérationnelle immédiate.

Références

- [1] Psaraftis, H. N. (1995). Dynamic vehicle routing : Status and prospects. *Annals of Operations Research*, 61, 143–164.
- [2] Pillac, V., Gendreau, M., Guéret, C., & Medaglia, A. L. (2013). A review of dynamic vehicle routing problems. *European Journal of Operational Research*, 225(1), 1–11.
- [3] Ceder, A. (2016). *Public transit planning and operation : Modeling and practice*. CRC Press.
- [4] Ropke, S., & Pisinger, D. (2006). An adaptive large neighborhood search heuristic for the pickup and delivery problem with time windows. *Transportation Science*, 40(4), 455–472.
- [5] Bengio, Y., Lodi, A., & Prouvost, A. (2021). Machine learning for combinatorial optimization : a methodological tour d’horizon. *European Journal of Operational Research*, 290(2), 405–421.
- [6] Mazyavkina, N., Sviridov, S., Ivanov, S., & Burnaev, E. (2021). Reinforcement learning for combinatorial optimization : A survey. *Computers & Operations Research*, 134, 105400.
- [7] Gurobi Optimization, LLC. (2023). *Gurobi Optimizer Reference Manual*.
- [8] Google. (2024). *OR-Tools : Google’s software suite for combinatorial optimization*. <https://developers.google.com/optimization>